Наивный байесовский классификатор

Цели работы:

- 1) практика создания п-грамм;
- 2) реализовать алгоритм наивного байесовского классификатора;
- 3) настройка штрафа ошибки с целью минимизации ошибки второго рода;
- 4) анализ результатов.

Набор данных

Рассмотрим задачу классификации электронных писем на два класса: спам (spam) и не спам (legit) и соответствующий набор данных. Архив содержит набор данных из писем, каждое из которых состоит из заголовка и текста сообщения. Набор данных уже разбит на 10 частей для перекрёстной проверки. В каждом письме слова закодированы в численном представлении для удобства.

Задание

n-граммы

Реализуйте преобразование, которое представляет письма в виде разреженного вектора признаков, либо модифицируйте преобразование используемое в соответствующей задаче на Codeforces. Преобразование должно поддерживать <u>праммы</u> и учитывать как заголовок, так и содержание письма. Попробуйте различные параметры сглаживания *alpha* и n для n-грамм. Обратите внимание, что несмотря на ограничения для задачи на Codeforces, параметр сглаживания *alpha* — это не обязательно целое число большее 1. Как правило, оптимальное значение вещественное и сильно близкое к 0. Параметр n не стоит брать слишком большим, достаточно проверить n = 1, 2, 3.

Обучение модели, настройка штрафа ошибки и анализ результатов

Обучите модель на предсказание класса письма. Постройте ROC кривую для обученной модели. Посчитайте точность (accuracy), используя перекрестную проверку (k-fold, где k=10).

Подберите штраф ошибки классификации λ_{legit} такой, чтобы ни одно реальное (legit) сообщение не было классифицировано как спам. Штраф λ_{spam} при этом должен быть зафиксирован.

Постройте график зависимости точности от параметра λ_{legit} , где λ_{legit} изменяется от значения по умолчанию (λ_{legit} = λ_{spam}) до найденного в предыдущем пункте значения.